文章编号：1000-3673（2026）03-0909-13　　中图分类号：TM 721　　文献标志码：A　　学科代码：470·40

面向电网分析计算的图神经网络技术综述

高昆仑，姚铁锤，刘思言，王轶申，张文思，万子豪，邓杰
（中国电力科学研究院有限公司，北京市 海淀区 100192）

A Survey of Graph Neural Networks Technology for Power Grid Analysis and Computation

GAO Kunlun, YAO Tiechui, LIU Siyan, WANG Yishen, ZHANG Wensi, WAN Zihao, DENG Jie
(China Electric Power Research Institute, Haidian District, Beijing 100192, China)

ABSTRACT: With the development of artificial intelligence, models represented by deep neural networks (DNN) have been widely applied in power grid analysis and computation. However, these models still struggle to directly process data with complex topological structures, such as power grid mapping. Graph Neural Networks (GNN) can effectively capture the relationships between nodes and the global information of graphs, addressing the limitations of traditional DNN in processing graph-structured data. This paper systematically summarizes the current applications and limitations of GNN in various power grid analysis and computation scenarios, including data generation, renewable energy and load forecasting, power flow calculation, state estimation, transient analysis, and optimal power system dispatch. This paper also analyzes the advantages and challenges faced by GNN in this domain. Finally, this paper presents an outlook on future research directions for GNN in power grid analysis and computation.

KEY WORDS: graph neural networks; power grid analysis and calculation; power grid topological graph

摘要：随着人工智能技术的发展，以深度神经网络为代表的模型在电网分析计算中得到广泛应用，但仍然难以直接处理复杂拓扑结构的数据(如电网拓扑映射)。图神经网络能够有效捕捉节点间的关系和图的全局信息，有效解决了传统深度神经网络在图结构数据处理中的不足。该文系统总结了图神经网络在数据生成、源荷预测、潮流计算、状态估计、暂态分析和优化调度等多个电网分析计算场景的应用现状和局限性，并分析了图神经网络在电网分析计算中的优势和面临的挑战，最后展望了图神经网络在电网分析计算中未来的研究方向。

关键词：图神经网络；电网分析计算；电网拓扑图

DOI：10.13335/j.1000-3673.pst.2025.1184

基金项目：国家重点研发计划项目(2022YFB2404200)。

Project Supported by the National Key R&D Program of China (2022 YFB2404200).

0　引言

随着信息通信、计算机、自动化、人工智能等技术的迅猛发展，电网正朝着数字化智能化方向转型，以深度神经网络(deep neural networks，DNN)为代表的人工智能技术已经在电网分析计算的多个场景中得到广泛应用[1-2]。深度神经网络通过多层次的非线性变换堆叠，可以从数据中提取深层特征，其中具有代表性的神经网络包括循环神经网络(recurrent neural networks，RNN)、卷积神经网络(convolutional neural networks，CNN)、生成式对抗网络(generative adversarial networks，GAN)和自编码器等。虽然深度神经网络在状态估计[3]、配电网关系辨识[4]、源荷预测[5]场景下处理实时量测、光伏功率等欧氏空间下的序列数据时表现出色，但其难以直接捕获和建模电网拓扑图的空间特征。

为了解决传统深度神经网络无法直接处理非欧空间数据的问题，图神经网络(graph neural networks，GNN)应运而生。图神经网络专门被设计用于处理图结构数据，是采用深度学习技术实现图计算的主流方法之一，其通过局部邻域聚合和图卷积等技术，能够有效地捕捉节点间的关系和图的全局信息，动态地调整节点的表示，更好地表征图结构的复杂性。与传统的深度神经网络相比，图神经网络具备处理复杂拓扑关系的能力，一定程度上解决了传统深度神经网络在图结构数据处理中的局限性。而电网拓扑结构关系日益复杂、规模不断增大，作为天然的物理网络，其物理拓扑能够被便捷地抽象为图数据结构，这使得图神经网络在电网的建模、表征、分析与计算中具备天然的适配性。电网图建模主要遵循两种范式：第一种范式为设备级建模，将发电机、负荷、母线等设备建模为图节点，设备间的连接关系建模为边；第二种范式为等效电路建模，将等效电气支路建模为边，多个支路的电

中国知网　https://www.cnki.net

气连接点建模为图节点。在等效支路建模中，图建模粒度取决于分析计算任务类型，潮流计算、状态估计等稳态分析任务通常采用粗粒度等效建模，节点、边往往聚合多个物理设备，而暂态分析任务中可以将同步发电机、逆变器等单个物理设备建模为包含多个节点的子图。通过不同范式的图建模，GNN 可以方便地适配电网复杂计算、分析推演等下游任务，并能够支持超大规模电网拓扑条件下的建模计算。

目前，深度神经网络在电网源网荷等场景应用的综述研究相对完善，图神经网络模型架构在计算机科学领域的研究已较为丰富，在电力系统中的适配性问题也有相关综述研究[6]，但仍然缺乏面向电网分析计算的系统性综述研究。鉴于图神经网络在电网分析计算中的巨大潜力，本文首先针对基础的图神经网络及其变体进行简要概述，简述图卷积神经网络、图注意力神经网络、图循环神经网络、时空图神经网络等几类有代表性的图神经网络。其次，围绕数据生成、源荷预测、潮流计算、状态估计、暂态分析、优化调度等 6 个电网分析计算典型任务，综述图神经网络的应用现状并做详细分析。然后，依据应用现状，归纳总结图神经网络的优势与应用中存在的挑战，最后对图神经网络应用的未来发展趋势进行了展望。

1 图神经网络技术概述

1.1 图的定义及表示

图结构化数据一般表示为 $\boldsymbol{G}=(\boldsymbol{V},\boldsymbol{E})$，其中 $\boldsymbol{E}$ 为边的集合，$\boldsymbol{V}$ 为节点集合。具体来说，v_i 表示图中的第 i 个节点，e_{ij} 表示从第 i 个节点到第 j 个节点的边。对于第 i 个节点，其邻域可以表示为 $\boldsymbol{N}(v_i)=\{u_i\in\boldsymbol{V}\,|\,(v_i,u_i)\in\boldsymbol{E}\}$。GNN 在电力系统中对不同场景下的问题进行建模时，可采用无向图、有向图、无权图、带权图、异构图、动态图等类型；从存储结构和代数两方面考虑，使用邻接矩阵表示法和拉普拉斯矩阵表示法的情况较多。

首先是邻接矩阵表示法。该方法采用二维矩阵来表示图中节点与节点之间的连接关系，以无权图为例，在无向图中，如果节点 i 与节点 j 有边相连，则 $e_{ij}=1$，否则 $e_{ij}=0$。而在有向图中，如果存在由 i 节点指向 j 节点的边，但不存在由 j 节点指向 i 节点的边，则 $e_{ij}=1$，$e_{ji}=0$。

其次是拉普拉斯矩阵表示法。拉普拉斯矩阵 $\boldsymbol{L}$ 也被称为导纳矩阵、基尔霍夫矩阵或离散拉普拉斯算子。详细数学定义如下：

$$\boldsymbol{L}=\boldsymbol{D}-\boldsymbol{A} \tag{1}$$

式中：$\boldsymbol{A}$ 表示邻接矩阵；$\boldsymbol{D}$ 表示度矩阵。一般来讲，拉普拉斯矩阵通常需要对称归一化。以拉普拉斯矩阵表示为基础，增加归一化操作之后，便可得到对称归一化之后的拉普拉斯矩阵 $\boldsymbol{L}^{\mathrm{sys}}$。其数学定义如下：

$$\boldsymbol{L}^{\mathrm{sys}}=\boldsymbol{I}_n-\boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{A}\boldsymbol{D}^{-\frac{1}{2}} \tag{2}$$

式中：$\boldsymbol{I}_n\in\mathbf{R}^{n\times n}$ 表示单位矩阵；n 为矩阵维度，即节点数目。

1.2 图神经网络模型

表 1 列出了 GNN 的经典类型及变体，后文将对图神经网络几类经典模型及其变体展开简要概述。

表 1 常见图神经网络及其变种

Table 1 Common graph neural networks and their variants

类型	变体	主要功能
图卷积神经网络(GCN)	基于谱域的网络：ChebGCN[7]、GCN[8]；基于空间域的网络：NN4G[9]、Cluster-GCN[10]、DCNN[11]	提取图结构数据特征
图注意力神经网络(GAT)	GAT[12]、SpGAT[13]、SAGNN[14]	根据节点间权重分配关系并提取特征
图循环神经网络(GRNN)	GRU[15]、Tree-LSTM[16]	解决图结构数据的长期依赖关系
图生成神经网络(GGNN)	GAE[17]、GVAE[18]、GGAN[19]、Graph Model[20]、MolGAN[21]	生成新的图结构
时空图神经网络(ST-GNN)	ST-GRNN[22] ST-GCN[23-25]	从时空图中提取特征

1.2.1 图卷积神经网络

图卷积神经网络(graph convolutional network，GCN)是图神经网络中的一个重要的分支。其进行卷积操作的方法主要分为 2 种，一种是基于谱域的卷积操作，另一种是基于空间域的卷积操作。由于两类 GCN 都有大量的变体，因此仅列出几个经典模型来说明其原理和结构。

1）谱分解图卷积。

谱图卷积的核心思想是将图信号从空间域转换到图的谱域进行处理，最后再转换回空间域输出结果。该方法的灵感来源于信号处理中频域变换。

谱图卷积的基础是图的拉普拉斯矩阵，谱分解图卷积的优势在于能够捕获图结构中的全局信息，然而，其也存在一些局限性，例如特征值分解计算复杂度较高，导致大规模图数据处理效率低。文献[8]以近似的方式在空间域上实现了谱分解卷积：

中国知网 https://www.cnki.net

$$\boldsymbol{H}^{(k)}=\rho(\tilde{\boldsymbol{D}}^{-\frac{1}{2}}\tilde{\boldsymbol{A}}\tilde{\boldsymbol{D}}^{\frac{1}{2}}\boldsymbol{H}^{(k-1)}\boldsymbol{W}^{(k-1)}) \tag{3}$$

式中：$\tilde{\boldsymbol{A}}$ 为自环邻接矩阵，其由邻接矩阵 $\boldsymbol{A}$ 与单位矩阵 $\boldsymbol{I}_n$ 相加而得；$\tilde{\boldsymbol{D}}$ 为归一化的度矩阵；$\boldsymbol{H}^{(k)}$ 和 $\boldsymbol{H}^{(k-1)}$ 分别为网络第 k 和 $(k-1)$ 层的隐含特征；$\boldsymbol{W}^{(k-1)}$ 为网络 $(k-1)$ 层的可学习参数；ρ 为非线性激活函数。

2）空间域图卷积。

空间域图卷积则是直接按照图的结构，根据相邻顶点间的关系以及每个顶点自身属性以得到新的特征，不需要使用拉普拉斯矩阵进行复杂的变换。

文献[9]提出的空间域图卷积网络(neural network for graph，NN4G)通过直接累加近邻节点的信息来实现图的卷积，从而建模邻域特征。此外，其还通过跳层连接的方式保留图的原始信息。NN4G 每一层的隐藏特征均考虑了节点初始特征和之前每一层的特征，这使得邻域信息融合较为充分。但在聚合信息过程中，NN4G 采用的是未经归一化的原始邻接矩阵，因此其存在数值稳定性较差、感受野受限等问题。Cluster-GCN[10]则通过将图本身划分为多个子图进行分别计算，可支持更大规模的输入图。在 NN4G 的基础上，文献[11]提出了扩散卷积神经网络(diffusion convolutional neural network，DCNN)，其将归一化后的邻接矩阵作为概率转移矩阵，以随机游走的方式实现了邻域信息的聚合。DCNN 的归一化操作提高了数值稳定性，且其考虑了多阶段近邻，扩大了感受野，更有利于大范围获取周围节点信息。

1.2.2　图注意力神经网络

图注意力神经网络(graph attention networks，GAT)[12]在传统的 GNN 的架构上加入了注意力机制。GAT 在注意力机制的激活下，通过修正图卷积运算，可以得到图中各相邻节点的权重占比，着重关注权重较大的节点，减少对权重较小节点的关注。由于 GAT 不完全依赖邻接矩阵，因此其对抗拓扑变化的能力较强。

此外，多头注意力机制被用来稳定学习过程。把原来只利用一个函数计算注意力因子改为设置为个不同的子模块分别计算注意力因子，每个子模块的结果都可以得到一组注意力权重。个注意力子模块互不影响，最后把每个注意力子模块得到的结果拼接，即可得到最后的结果：

$$\boldsymbol{h}_i^{'}=\|_{k=1}^{K}\delta[\Sigma_{j\in\boldsymbol{N}(v_i)}\alpha_{ij}^{k}\boldsymbol{W}^{k}\boldsymbol{h}_j] \tag{4}$$

式中：$\|$ 表示拼接操作；α_{ij}^{k} 是第 k 个注意力参数函数求得的节点 i、j 之间的注意力因子；$\boldsymbol{h}_j$ 为第 j 个节点的隐含特征；$\boldsymbol{W}^{k}$ 为第 k 层可学习参数；$\boldsymbol{h}_i'$ 为节点 i 的输出特征。在 GAT 的基础上，文献[14]改进了 GAT 并进一步提出了基于自注意力机制的图神经网络(self-attention graph neural network，SAGNN)等一系列图注意力机制模型。

1.2.3　图循环神经网络

RNN 在时间序列预测等领域取得了显著的成果，图循环神经网络(graph recurrent neural networks，GRNN)[15]是循环神经网络和图神经网络的结合，当待处理时序数据具备明显图结构时，这种神经网络具备较大优势。

对节点 v，GRNN 首先依据邻接矩阵收集周围节点特征，并以此生成对上一时刻特征的重置系数和遗忘系数：

$$\boldsymbol{a}_v^{(t)}=\boldsymbol{A}\boldsymbol{H}^{(t-1)}+b \tag{5}$$

$$\boldsymbol{z}_v^{(t)}=\sigma[\boldsymbol{W}^{z}\boldsymbol{a}_v^{(t)}+\boldsymbol{U}^{z}\boldsymbol{h}_v^{(t-1)}] \tag{6}$$

$$\boldsymbol{r}_v^{(t)}=\sigma[\boldsymbol{W}^{r}\boldsymbol{a}_v^{(t)}+\boldsymbol{U}^{r}\boldsymbol{h}_v^{(t-1)}] \tag{7}$$

式中：$\boldsymbol{a}_v^{(t)}$ 代表由近邻节点信息聚合而成的中间特征向量；$\boldsymbol{A}$ 为邻接矩阵；$\boldsymbol{b}$ 为可学习的偏置参数；$\boldsymbol{z}_v^{(t)}$ 和 $\boldsymbol{r}_v^{(t)}$ 分别代表遗忘系数和重置系数；$\boldsymbol{W}^{z}$、$\boldsymbol{U}^{z}$、$\boldsymbol{W}^{r}$ 以及 $\boldsymbol{U}^{r}$ 均为可学习参数；$\boldsymbol{h}_v^{(t-1)}$ 对应 $t-1$ 时刻节点 v 的隐含特征。

接下来 GRNN 利用重置系数生成本时刻隐含特征的中间值，再结合遗忘系数对之前时刻的信息进行融合：

$$\tilde{\boldsymbol{h}}_v^{(t)}=\tan h[\boldsymbol{W}\boldsymbol{a}_v^{(t)}+\boldsymbol{U}(\boldsymbol{r}_v^{(t)}\odot\boldsymbol{h}_v^{(t-1)})] \tag{8}$$

$$\boldsymbol{h}_v^{(t)}=(1-\boldsymbol{z}_v^{(t)})\odot\boldsymbol{h}_v^{(t-1)}+\boldsymbol{z}_v^{(t)}\tilde{\boldsymbol{h}}_v^{(t)} \tag{9}$$

式中：$\tilde{\boldsymbol{h}}_v^{(t)}$ 代表由重置系数生成的本时刻隐含特征的中间值，其经过遗忘系数 $\boldsymbol{z}_v^{(t)}$ 的处理后，成功融合了上一时刻的隐含特征 $\boldsymbol{h}_v^{(t-1)}$；$\boldsymbol{W}$、$\boldsymbol{U}$ 均为可学习参数；$\boldsymbol{h}_v^{(t)}$ 为该层输出；$\odot$ 代表哈达玛积。由于在重置系数和遗忘系数的生成过程中，均考虑了网络拓扑结构，因此 GRNN 实现了在图结构上的递归，兼顾了拓扑和时序 2 个维度。

1.2.4　图生成神经网络

从已有的图中抽取特征信息的逆过程，即利用已有信息生成新图或子图的网络被称为图生成神经网络(graph ggenerative neural network，GGNN)。图自编码器[17-18]、图卷积对抗生成网络[19]、Graph Model[20]是具有代表性的图生成神经网络。Graph Model 采用迭代的方式逐步生成一个完整的图，其序列决策的模式使得每一步要解决的任务较为简单，生成的图更加可靠。

中国知网　https://www.cnki.net

除序列决策模式外，生成对抗技术也在图生成神经网络中得到广泛应用。MolGAN[21]将图卷积网络、生成对抗网络和强化学习融合在一起，首先让生成器生成一个伪图并初始化其特征矩阵，之后由判别器来区分样本真伪，并用强化学习来为判别器训练一个奖励网络。这使得生成的图可以具有更多属性，满足更多约束。

1.2.5 时空图神经网络

时空图神经网络(spatial-temporal graph neural networks，ST-GNN)[26]将图神经网络扩展到时空图模型上。

在时空图神经网络中，每个时间步均对应一个图。在每个时间步长内部，遵循待预测对象的自身拓扑结构，生成物理边。在相邻时间步长中将同一个节点连接起来，构成时间边。上述所有节点和边构成的图即为时空图。ST-GNN 可交替使用空间图神经网络模块和时间图神经网络模块以完成复杂时空特征提取。

1.2.6 图神经网络其他变体

近年来，除上述典型类别外，图神经网络还涌现出多种变体。文献[27]提出了一种新的图网络与注意力融合的架构 Graphformer，其将 GNN 组件与 Transformer 层并行设置，并引入单向图注意力机制，实现了高效整合长距离图信息的能力。此外，针对节点与边物理意义多样化的复杂情况，文献[28]提出了异构图网络，其对不同物理意义的边与节点分别进行编码，增强了模型对物理规律的建模能力。在此基础上，文献[29]提出了异构图注意力神经网络，在节点邻接性与语义相似性 2 个层面生成中心节点对邻接节点的注意力，从而提高了节点信息的稳定性和模型训练的收敛性。

2 图神经网络在电网分析计算中的研究现状

本节围绕电网分析计算中的数据生成、源荷预测、潮流计算、状态估计、暂态分析、优化调度等场景应用分别总结其关键任务、代表性算法和建模方法，总览见表 2。

2.1 数据生成

通过模拟真实电网拓扑结构、物理参数、源荷功率的数据分布，基于图神经网络的数据生成方法能够为电力系统模拟推演提供基础数据支撑，并为电力系统分析计算任务的人工智能模型训练、评估提供更为丰富的样本数据。

现有数据生成方面研究方法主要是图神经网络和生成式对抗网络的组合。文献[30]提出了基于生成对抗网络和图卷积网络的馈线自动生成方法 FeederGAN，可以高效地生成与实际配电网相似的馈线拓扑。该模型利用 GNN 从真实电网馈线中学习拓扑结构，并通过优化 Wasserstein 距离重建真实馈线拓扑，为配电网规划、配电网重构研究提供有效的测试数据。文献[31]提出了基于图卷积生成对抗网络的风电场景生成方法，可以生成具有真实时空统计特性的风电场景。该模型利用图过滤器嵌入多个风电场之间的空间相关性，并通过一维卷积层表示时间特征过滤器，提高了训练效率和计算性能。文献[32]提出了基于图神经网络的自适应预测生成对抗网络不仅用于预测风场的短期未来，还能为数据生成提供多样化的场景。该方法将原始的多元时间序列重构为图结构，利用图卷积网络提取时空特征，在预测生成对抗网络框架下根据历史观测条件生成多种可能的未来场景。为了保证生成数据的稳定性与质量，引入自适应预测式对抗生成网络训练机制，并设计综合评估体系筛选出最佳的场景生成模型。

综上所述，通过将图神经网络嵌入生成对抗网络框架，可以实现对电力系统复杂结构和风电运行特性的建模与再现，为配电网规划、重构和风电场仿真等场景提供了丰富的数据来源。然而，生成数据的有效性仍需开展充分的有效性验证，以确保用这些合成样本训练出的人工智能模型具备可靠的泛化能力。

2.2 源荷预测

随着新能源发电和新型负荷占比不断提升，源荷双侧运行不确定性对电网平衡和调控运行的影响愈发显著，精准、细粒度的新能源出力预测和负荷预测对于电力系统分析计算至关重要[33]。当前，图神经网络的应用主要覆盖多时间、空间尺度的风光发电预测和负荷预测。

风光发电预测方面，图神经网络应用主要覆盖超短期、短期预测时间尺度，建模方法通常是将风光场站视为节点，将物理拓扑连接或相似性作为边进行图建模，并采用图注意力神经网络、时空图神经网络提取场站的时空信息，进而进行出力预测。文献[34]中提出了一种图时空注意力神经网络预测分布式光伏的超短期功率。该网络结合卫星遥感数据来补充分布式光伏电站的气象信息，并利用图卷积模块对非欧几里得局部和全局空间依赖性进行建模。文献[35]提出了考虑静态图和动态图的图循环神经网络模型，通过将光伏板相关性建模为静态图，将数值天气预报数据和光伏出力等信息建模为

中国知网 https://www.cnki.net

表 2　图神经网络在电网分析计算中的应用分类

Table 2　Application classification of graph neural networks in power grid analysis and computation

场景应用	具体任务	图神经网络类型	建模方式
数据生成	自动馈线生成	图卷积对抗生成网络[30-32]	将配网馈线建模为属性异构图，采用顺序自回归的方式，添加新节点并预测其与其他节点的连接
	风电场景生成		利用图结构建模风电场群的空间相关关系，并结合时序卷积提取时间特征
	风场未来场景预测		利用图结构动态自适应构建风电场群的空间相关关系，并结合时序卷积提取时间特征
源荷预测	超短期光伏发电预测	图时空注意力神经网络[34]	引入卫星云图数据，提取空间相关性
		图循环神经网络[35]	引入数值天气预报数据，提取时空相关性
	短期光伏发电预测	空间卷积图神经网络[36]	引入空间图模型，局部特征和全局特征结合
	超短期风电预测	时空图神经网络[37-38]	引入功率波动模式概念，对每种模式进行训练
	短期风电预测	全局信息自适应图卷积网络[39]	结合风电场的相关性特征，设计提取多种图结构特征
	短期负荷预测	图卷积网络[40]	对用户集群聚类划分，然后进行图建模
		时空图卷积网络[41]	将外部因素建模为动态属性和静态属性，利用快速最大互信息系数建模各节点负荷的耦合信息
		并行时空图注意力神经网络[42]	对多个负荷序列分别建模并划分子图，然后并行使用图注意力神经网络对各个子图提取特征
	超短期负荷预测	时空图神经网络[43]	考虑历史负荷、地理位置信息、临近区域空间数据共同建立图结构
	中长期负荷预测	自适应图神经网络[44]	采用注意力机制和自适应图建模负荷波动性，结合图神经网络和卷积神经网络实现中长期负荷预测
潮流计算	潮流计算	图卷积神经网络[46, 48, 50]	利用电力系统的拓扑连接、稳态状态，实现潮流状态预测
		双视角图注意力神经网络[49]	
	直流电网潮流计算	图卷积网络[47]	
状态估计	状态估计	消息传递图神经网络[52]	基于电网拓扑、状态量测建立图结构，结合门控循环单元与图神经网络实现特征提取
		自适应时空图神经网络[53]	以电网拓扑为空间信息、以量测为时序信息构建时空图，预测电网稳态状态
		图卷积网络+图注意力神经网络[54-55]	基于电网拓扑、状态量测建立图结构，结合全局图注意力实现特征提取
			以母线为节点、以输电线路及测量单元抽象为因子节点，形成双向连接的因子图结构，动态聚合母线节点与测量因子节点的信息
		图注意力神经网络[56]	基于电网拓扑、状态量测建立图结构，利用图注意力神经网络实现状态估计
暂态分析	暂态稳定评估	图卷积网络[57-58]	基于电网拓扑、稳态状态与故障类型建立图结构
		时空图卷积网络[59-60]	基于电网拓扑、暂态状态建立图结构
	过电压评估	图卷积网络[61]	基于电网拓扑、稳态状态、直流故障建立电网图结构
	动态过程预测	物理信息图神经网络[62]	基于电网拓扑、暂态状态变化量建立图结构
优化调度	有功功率校正控制	图注意力神经网络[63]	基于电网拓扑、有功出力、电压偏差构建图结构，预测功率调整量
	电压控制/无功优化	时空图卷积网络[65]	基于电网拓扑、稳态状态建立图结构，预测发电机无功调整或储能充放电动作
		图卷积网络[66]	基于电网拓扑、电气状态量建立图结构，预测近端节点电压调节量
		物理信息时空图神经网络[67]	基于配电网拓扑、稳态状态预测建立图结构，输出优化后配网开关状态与电压控制量
	机组组合优化	时序图卷积网络[68-69]	基于电网拓扑、负荷预测建立图结构，预测机组启停与出力

分层有向图，进行超短期光伏功率预测。文献[36]提出了一种双层结构模型用于区域性短期光伏功率预测，该模型在局部层和全局层分别利用有向图模型的动态空间卷积图神经网络和动态图池化方法学习光伏电站的表示特征，并映射到区域光伏发电的概率预测。文献[37]提出了一种基于时空相关性的风电功率预测方法，利用空间注意力层和时间注意力层对不同风机之间的时空相关性进行聚合提取，并通过谱卷积层和时间维度卷积捕捉风电数据之间的空间特征和时间演变规律。文献[38]提出了一种基于功率波动模式识别与时空图神经网络的风电场群超短期功率预测模型，该模型将风电场

中国知网　https://www.cnki.net

群功率数据划分为多种模式，并利用时空图神经网络针对每种波动模式进行训练。文献[39]提出了基于全局信息自适应感知图卷积的风电场群短期功率预测方法，该方法根据风电场间的相关性，设计了多种特征图结构，并建立自适应图卷积网络。

负荷预测方面，图神经网络应用主要覆盖短期、中长期时间尺度和居民负荷、电动汽车负荷等用户类型，研究方法与风光发电预测类似，通常是将负荷侧视为节点，负荷用户相似性或地理信息建模为边，采用图注意力神经网络、时空图神经网络预测未来负荷。在用户集群负荷预测中，文献[40]提出了一种基于图卷积神经网络与K-means聚类的居民用户集群短期负荷预测方法。该方法将居民用户集群按照用电行为相似性划分成不同组并构建不同相似度的时空图数据，然后采用图卷积神经网络实现居民用户集群短期负荷预测。文献[41]提出一种基于属性增强的多尺度时空图卷积神经网络与 Transformer 融合的电力系统多节点负荷预测方法，通过多尺度时空图卷积网络挖掘负荷短期时空特征，通过 Transformer 模块挖掘负荷长期时域特征，最终利用门控层融合 2 个模型提取的特征进行负荷预测。文献[42]提出了一种并行时空图注意力神经网络的短期负荷预测模型。该模型将多序列负荷编码为节点，采用多时间尺度、多分支方法划分子图，利用图注意力神经网络对每个子图单独进行特征提取，最终合并多分支进行负荷预测。在电动汽车充放电负荷预测中，文献[43]提出了一种基于时空多图卷积网络的超短期负荷预测方法。该方法根据充电站的历史负荷和地理信息建立图结构，并考虑了邻近区域充电站的空间数据。文献[44]提出了一种基于动态自适应图神经网络的中长期负荷预测算法。该方法采用注意力机制与自适应图结合方式建模充电站负荷的波动性，然后采用图卷积和多时间尺度卷积提升模型长时间负荷序列的预测能力。

综上所述，时空图神经网络、图注意力神经网络等图神经网络模型在源荷预测领域已有广泛的应用。大多研究通过分析源荷序列的数据特性，如特殊节气、相似日、相似站点、相似气象，构建不同的图数据特征，而图神经网络的核心优势在于可以直接静态或动态地处理上述图数据，进而提取多条风光功率序列或负荷序列数据的空间特征。然而，研究者在构建图数据时主要基于节点间历史数据相关性或节点间物理距离，而并非基于电网拓扑连接关系。因此，图数据构建方式和图神经网络特征提取模式依赖人工数据预处理和负荷用户及电网节气、新能源场站气象特征等先验知识，这使得图神经网络在源荷预测场景下的泛化性受限。

2.3 潮流计算

潮流计算是电力系统的核心分析计算任务之一，随着电力系统的设备数量增加，传统迭代求解方法面临收敛性差和计算效率低的问题[45]。近年来，已有部分研究将 GNN 应用于潮流计算中，由于潮流计算本质上是针对特定电网时间断面的稳态分析问题，因此无需考虑时间维度依赖，可直接利用图神经网络捕捉电网拓扑与电气量之间的复杂关联，预测电力系统的潮流分布。

现有研究主要可从图结构构建与神经网络架构设计 2 个维度进行分类。在图结构建模方面，主要分为基于物理拓扑的显式建图和基于谱图理论的隐式映射两类。文献[46]直接利用电网物理连接关系构建图结构，通过历史数据训练 GNN 预测关键线路潮流。文献[47]通过网络拓扑拉普拉斯矩阵的特征向量实现时域直流电网到谱域直流电网的空间正交变换，实现电气量与网络结构间的数据融合，通过估计节点电压实现直流电网潮流求解。在图神经网络架构设计方面，主要可分为 3 个阶段：第一阶段主要基于标准 GNN 结构，验证其在潮流计算任务中的可行性[46]。第二阶段集成了多样化的神经网络结构与机器学习方法，如文献[48]通过引入贝叶斯嵌入捕获潜在节点特征，并采用多任务学习框架在共享 GNN 权重的同时，有效区分不同变压器的个体行为模式，实现高压和特高压电平变压器的垂直功率流预测；文献[49]设计了异构特征提取层以处理不同类型节点的属性差异，并提出图自注意力聚合池化方法增强对复杂拓扑关系的表达能力，解决了潮流计算人工智能模型不具有潮流判敛能力的问题。第三阶段主要结合物理机理实现深度创新，如文献[50]定义了潮流卷积层，融合输电线路阻抗与相邻节点电压、功率等物理量特征，拟合局部功率流动规律，利用拓扑自适应图卷积模块聚合多跳范围内的节点特征以平衡全局关联，最终实现局部物理过程拟合和全局拓扑约束聚合的物理信息深度融合。

综上所述，现有工作利用 GNN 的消息传递机制提取节点邻域结构特征，并在损失函数部分引入了潮流一致性等物理约束以拟合非线性方程。然而，现有研究仍存在两方面局限：一是图神经网络的消息传递机制使得节点感受野受限，难以捕捉全局电网平衡状态；二是图神经网络模型训练与特定

中国知网 https://www.cnki.net

电网拓扑结构深度绑定，模型无法直接迁移至具有不同拓扑结构的电网。

2.4　状态估计

电力系统状态估计旨在利用冗余实时测量数据，计算系统最可能的运行状态，并辨识和剔除不良数据。尽管加权最小二乘法、卡尔曼滤波法等主流方法在冗余量测充足的主网中表现良好，但在参数异常、局部不可观等条件下，仍面临收敛困难或自由度不足等挑战。GNN 凭借其对电网拓扑结构的天然表征能力和对非线性函数的强大拟合能力，为状态估计提供了新的解决方案[51]。

现有研究可从节点特征构建方法和神经网络架构设计 2 个维度进行归纳。在节点特征构建方面，主要分为两类：一是直接使用实时量测数据作为节点特征，如文献[52]利用拓扑参数和实时量测信息构建图数据集，通过在不同拓扑下训练消息传递 GNN 获得通用状态估计模型；二是引入伪量测增强节点特征，如文献[53]提出了基于时空特征图卷积网络的方法，利用历史有功、无功注入数据为无传感器的节点生成伪量测并捕捉节点间时空关联，以提升配电网可观性。在神经网络架构设计方面，可划分为 3 个阶段：第一阶段是基于标准 GNN 框架的初步应用，如文献[52]直接采用标准 GNN 架构，文献[54]设计了基于图注意网络的异构架构，通过自适应权重分配机制近似加权最小二乘求解器，展现出对量测缺失的良好适应性。第二阶段是融合拓扑等物理知识的方法，如文献[55]提出了融入拓扑知识的配网抗差状态估计方法，利用拓扑一致性异常抑制及多尺度拓扑融合机制，结合拓扑结构抑制不良量测对状态估计结果的影响，有效提升对不良数据的鲁棒性。第三阶段是面向特定场景的多任务协同架构，如文献[56]提出了基于 GAT 的可重构配电网状态估计框架，通过拓扑辨识与状态估计两阶段神经网络协同，实现对拓扑变化场景的快速准确响应。

综上所述，GNN 在状态估计中的应用普遍侧重于节点特征的构建与增强以及图结构学习，通过融合多源量测数据和生成伪量测来提升系统可观性。值得注意的是，文献[52, 57]都显式考虑了模型对电网拓扑变化的适应能力。然而，现有方法仍面临两大挑战：一是电网实际量测数据噪声与异常值干扰显著；二是伪量测数据生成可能引入累计误差。

2.5　暂态分析

电力系统暂态分析旨在评估系统在遭受短路、负荷突变等扰动后的动态响应与稳定性。传统时域仿真方法计算耗时长，难以满足在线分析时效性要求，而电力电子器件广泛接入带来的时变性与非线性进一步增加了仿真复杂度。GNN 可根据电力系统各元件之间的关系学习电网运行特性并大幅提升分析速度，是数据驱动暂态分析的主流方法之一，主要应用于暂态稳定性评估、暂态安全评估、动态过程预测。

现有研究可从图结构建模方法和暂态分析任务 2 个维度进行分类。在图结构建模方面，主要包括两类：一是基于物理拓扑的静态图结构，如文献[57-58]以稳态数据与故障信息为输入构建图结构，分别实现暂态稳定分类和多重稳定性风险预测；二是引入时间维度的时空图结构，如文献[59-60, 63]通过构建时空图结构，联合提取时空特征实现更精细的稳定状态判别。

在暂态分析任务方面，可分为 3 类：一是暂态稳定性评估，文献[57]基于稳态数据和故障信息实现系统稳定性分类，并考虑了模型在拓扑变化下的泛化能力；文献[58]实现了小扰动稳定、功角稳定、电压稳定、频率稳定、换流器驱动稳定的多重风险连续预测；文献[59]使用门控卷积与图卷积提取电力系统时空特征实现系统稳定分类；文献[60]提出了结合注意力机制的残差时空图神经网络方法预测电网暂态稳定分类结果。二是暂态安全评估，文献[61]考虑直流闭锁、换相失败预想故障，基于图卷积神经网络评估直流送端系统暂态过电压峰值；文献[62]结合强化学习方法和图卷积网络，实现了暂态稳定评估与电网暂态安全预防控制。三是动态过程预测，文献[63]提出了一种物理信息动态图神经网络，融合数据驱动的注意力权重与物理导纳矩阵构建动态邻接矩阵，再以基尔霍夫定律约束作为损失函数惩罚项，实现精准动态过程预测。

综上所述，GNN 在暂态分析中的应用普遍侧重于利用拓扑结构捕捉动态过程中的空间关联，并通过引入时间扩展或物理约束增强模型性能。现有研究多数集中于暂态稳定评估问题，而在安全裕度评估、动态过程预测等任务上仍处于探索阶段。

2.6　优化调度

电网优化调度旨在满足系统安全约束和发用电实时平衡的前提下，通过协调发电机组、储能装置、可调负荷等资源，实现电网安全经济运行。不同于数学规划法，GNN 结合强化学习技术，将无功电压优化、机组组合、配电网重构等任务建模为马尔可夫过程并进行序贯求解。

现有研究可从关键应用场景与优化求解模型

中国知网　https://www.cnki.net

架构 2 个维度进行系统梳理。在应用场景方面，主要集中于以下 3 类：一是电压控制与新能源消纳，如文献[65]设计了多粒度注意力时空图卷积网络，结合深度确定性策略梯度实现电压优化与新能源消纳；文献[66]基于多智能体架构实现配电网电压分布式优化；文献[67]融合物理信息神经网络与时空图卷积网络，求解三相不平衡电网的重构与电压控制。二是机组组合优化，如文献[68]提出了约束图时序卷积网络，通过图卷积提取拓扑特征、时序卷积提取负荷特征，并利用约束激活层将特征投影至可行域内；文献[69]通过构建时空图神经网络，联合学习电网空间拓扑与历史时序特征以预测机组启停状态。三是有功调度与校正控制，如文献[64]提出了基于图注意力网络与蒙特卡洛树搜索的有功功率校正控制方法，通过奖励引导的差分探索策略提升动作评估效率。

在优化求解模型架构方面，根据算法融合的特点，可归纳为 3 类技术路线：一是 GNN 仅与强化学习深度融合，如文献[64-65]将 GNN 与强化学习相结合，通过环境交互学习最优控制策略；二是基于 GNN 的分布式优化架构，如文献[66]采用多智能体架构实现分布式协同决策；三是物理约束嵌入的 GNN 架构，如文献[67-68]将物理约束相关量显式编码为节点输入特征，增强输出结果的可行性与可靠性。

综上所述，GNN 在优化调度中普遍侧重于从电网拓扑和时空量测中提取特征，并通过端到端学习或与环境交互逼近最优决策。然而，大多数研究仍停留在仿真验证阶段，面临训练成本高、对拓扑和运行条件变化的泛化能力不足等挑战，距离实际工程应用仍有较大差距。

3 图神经网络应用于电网分析计算的优势与挑战

3.1 优势

图神经网络在处理大规模复杂电网时具有更高的计算效率和更好的适应性。

首先，图神经网络的结构与电网结构高度适配，可以实现一一对应，例如：电网节点可以建模为图网络节点，电网输电线路、变压器可以建模为图网络的边。甚至可以采用异构图网络对不同的电气设备乃至不同电压等级的电气设备进行更细化的建模。上述特性使得图神经网络在处理电网调度运行中需要精确计算的任务(潮流计算、状态估计等)时具有天然优势，图网络可以更智能化地表征电网中设备关系，更充分地建模设备的电气特性，从而完成更加符合物理一致性的预测。

其次，图神经网络相较于传统全连接神经网络对拓扑结构具有更强的适应性。当电网拓扑发生变动(如线路故障、负载节点增多)时，图网络可通过动态更新节点和边的连接关系，增量化快速重构模型，从而避免传统方法需从零开始重新训练的问题。

最后，图神经网络在大规模计算时具有效率优势。例如，在潮流计算中，基于牛顿拉夫逊法的传统潮流计算方法的收敛效率和预测精度均严重依赖初值设定，如果初始值设定距离最终结果较远，则可能出现模型迭代次数过多甚至最终不收敛的情况。相比之下，基于图神经网络的方法不依赖人工设定的初始值，且其内部的矩阵运算能够高效收集节点信息，从鲁棒性和运行效率上均具备较大优势。

3.2 挑战

首先，图神经网络对拓扑的依赖程度较高，对拓扑干扰的鲁棒性较差。当极端天气导致某些线路损坏时，配网拓扑结构将发生剧烈改变，此时基于完整拓扑结构训练的图神经网络难以迁移到改变后的拓扑上。另外，传统图神经网络中的节点交互方式使感受野较为受限，即每一层中每个节点只能关注到一阶近邻点。近年来，有学者构建基于高阶近邻矩阵的图网络，这种结构虽然提升了图网络的大范围特征建模能力，但导致图神经网络对拓扑干扰的鲁棒性进一步降低，限制了其在配网状态估计、潮流计算中的应用。因此，优化支持动态图的图神经网络模型，提高图神经网络的泛化性仍是当前的挑战之一。

其次，图神经网络在电网分析计算应用方面的可解释性仍有待提高。从模型性能提升角度，图神经网络模型可以通过在归一化、Dropout、层链接方式、模型深度广度等方面调整进一步提升其性能[70]，从 GCN 到 Graph Transformer，研究者提出的一系列图神经网络模型变体在节点分类、链接预测和图分类等任务的适用性仍然需要在超参调优、架构自身可解释性等方面进一步探索和研究。从可解释工具结合角度，GNN Shap[71-72]、Graph LIME[73]、GNN Explainer[74]等可解释人工智能技术与图神经网络结合的应用通常是基于结果进行反向分析解释，仅可在一定程度上增强模型推理的可解释性。在电网数据生成、源荷预测、潮流计算、状态估计、暂态分析、优化调度等场景下，构建高可解释性的图神经网络仍然是当前的挑战之一。

然后，图神经网络作为一种数据驱动方法，其

中国知网 https://www.cnki.net

输入输出间映射关系通过模型参数寻优得到(如梯度下降法)，难以确保其直接满足电力系统物理约束。当前研究中物理信息嵌入与表征方式共有 3 种：一是将问题中的电网拓扑、约束条件等信息与电气状态量共同显式编码为输入特征的一部分，以增强模型对原物理问题的感知，如文献[54, 67-68]；二是将物理方程残差作为损失函数中的惩罚项，引导图神经网络训练，如文献[63]；三是设计与物理方程计算形式相同的图神经网络模块，如文献[50]。但是电力物理方程仍难以作为强约束嵌入图神经网络，比如满足欧姆定律、基尔霍夫定律等基本条件。此外，配电网结构复杂、节点规模庞大，这使得用于图神经网络训练的电网拓扑图数据较难构建。这种困难在实际数据采集和仿真数据生成两方面均有体现。在实际数据采集方面，由于配电网中大量节点缺少 PMU 或 SCADA 等量测系统，配电网的可观性较差、数据质量较低。即使现有许多模型能够构建伪量测数据，但累计误差的存在使其无法直接用于训练下游图神经网络。在仿真数据生成方面，虽然有 PyPower 等工具可以辅助配电网仿真模型搭建和潮流分析，但仿真模型的初始负荷状态需要人为设定，其能模拟的场景远远无法涵盖实际系统中的复杂情况，例如源端新能源光伏发电会受到天气影响，负载端汽车充电桩负荷变化随机性较大等。因此，设计满足电力系统物理约束和支持复杂电网拓扑图输入的图神经网络仍然是当前的挑战之一。

最后，图神经网络的开发生态仍不完善。一方面，现有的深度学习框架在支持面向电力应用的图神经网络训练方面存在显著不足。主流深度学习框架如 PyTorch 和 TensorFlow 主要针对模型和数据量较大但采样数据规模较小(例如单幅图像)的场景进行优化，其并行计算策略通常依赖于在多个设备(如 GPU)上划分批量输入样本。然而，这种设计并不适用于处理电力系统中常见的不规则拓扑图数据。特别是在电力应用领域，电网拓扑图具有复杂的物理映射关系，这些拓扑图无法直接作为图神经网络的输入，导致现有框架在电力系统应用中的适配性较差。另一方面，当前主流的图神经网络算法库(如 PyG 和 DGL)底层依赖于 PyTorch 或 TensorFlow 框架，其硬件兼容方面仅对 CPU 和 NVIDIA GPU 支持较为友好，对其他主流加速卡的适配性尚不完善。此类图神经网络算法库同样缺乏面向电力应用的专门优化，这进一步限制了这些算法库在电力系统中的应用潜力。总之，现有图神经网络算法库和深度学习框架在电力系统应用中的支持尚不完善，既难以直接处理电网拓扑图输入，也缺乏对硬件兼容性专门适配，是当前图神经网络生态方面的主要挑战之一。

4 未来研究方向

4.1 高泛化性的图神经网络

电力系统存在拓扑动态变化、工况复杂多样、新能源特性异化、跨区域场景差异显著等特点，要求图神经网络在不同拓扑、工况和场景下保持稳定性能。传统图神经网络依赖特定场景训练数据，面对拓扑重构、新设备接入等未见过的场景时性能易大幅下降，难以适配新型电力系统需求。在模型设计层面，提升泛化能力的架构改进主要包括 3 个方面：1）引入拓扑自适应机制，通过动态图卷积算子自动适配不同电网拓扑；2）构建多尺度特征融合网络，整合宏观运行特性与微观设备特征；3）借鉴元学习思想设计“任务自适应参数”，实现模型向新场景的快速迁移。在数据增强策略方面，提升泛化性能力的改进主要包括：1）基于领域自适应的生成模型可迁移成熟场景数据至新场景，消除分布差异；2）利用机理知识构建虚拟场景生成器，生成跨场景样本扩充训练数据覆盖范围；3）通过拓扑扰动、噪声注入等数据增广技术，增强模型对数据扰动的鲁棒性。在模型调优与迁移方面，需要研究跨场景调优方法，如通过少样本图学习的“预训练+微调”模式快速适配新场景、通过多任务联合训练提升跨任务泛化能力等。

未来，高泛化性图神经网络将向通用基础模型和场景适配方向协同发展，需构建电力领域通用基础模型，并研究轻量级可迁移适配技术，以更好应对新型电力系统动态变化，支撑跨区域、跨场景智能化应用。

4.2 可解释的图神经网络

相较于传统电力系统分析方法具备明确物理机理推导过程的优势，当前图神经网络在电力系统应用中仅能从反向解释等角度实现局部可解释性，其可解释性与电网实用安全保障需求间仍存在差距。电力系统具有规模巨大且不完全可观、机电-电磁-多物理场等机理知识、极端工况下的样本极度缺乏、决策容错率低等显著特点，这对图神经网络的可解释性提出了更高要求。未来可结合可解释技术增强图神经网络的可解释性。

在可解释性技术应用层面，已有多项可解释 AI 技术和图神经网络结合的研究，但其在电网分析计算场景的应用仍几乎处于空白。例如，GNN Shap

中国知网 https://www.cnki.net

借助 Shapley 值原理，有效平衡了图神经网络解释的可扩展性与准确性，能够量化各节点特征对模型决策结果的贡献程度[71]；在电力系统暂态稳定评估研究中，文献[72]基于图神经网络与 SHAP 值构建分析框架，提取影响暂态稳定的关键特征及节点贡献度，提升了模型决策的可信度。Graph LIME 则通过 Lasso 特征选择方法，在节点子图范围内构建局部解释模型，为图神经网络的决策逻辑提供了直观的可解释依据[73]；GNN Explainer 进一步通过最大化互信息与变分推理技术，针对节点、边及图层面的预测任务，返回最小关键子图和关键节点特征子集的解释结果，精准定位模型决策的核心依据[74]。

未来，面向电网分析计算的图神经网络研究需进一步聚焦可解释性技术与电网分析计算实际场景的深度融合，以更好地支撑电力系统的稳定运行与智能化决策。

4.3 满足物理机理约束的图神经网络

图神经网络技术在电网分析计算中应着重考虑满足相关物理机理约束。电力系统存在能量守恒、基尔霍夫定律等底层物理机理，且具有拓扑动态变化、设备耦合交互等特点。以上特性决定了图神经网络在电网分析计算应用必须深度融入物理机理约束，否则可能输出违反物理规律的决策，引发安全风险。

在模型构建层面，物理机理嵌入方式主要有两类：一是将物理方程显式编码到网络结构中，如将潮流方程的功率平衡关系转化为节点消息传递规则；二是通过机理约束的图结构设计实现隐式融合，例如按欧姆定律构建邻接矩阵等。同时，可针对设备物理特性设计专用节点特征编码模块。

在模型训练优化过程方面，则主要以物理机理为引导。通过构建机理感知的损失函数，加入电压幅值、频率偏差等硬约束惩罚项；利用物理机理生成虚拟样本扩充训练集，既能丰富数据多样性，又能保证样本符合物理规律，帮助模型学习鲁棒特征。例如，文献[75]系统总结了物理信息神经网络在状态估计、动态分析、潮流计算、最优潮流、异常检测与定位以及模型和数据合成等应用的范式。未来，图神经网络在电网分析计算应用主要考虑弱物理机理约束范式和强物理机理约束范式结合的建模方法。

5 结论

图神经网络作为一种专门处理非欧空间数据结构的深度学习模型，在电网分析计算中展现出巨大的应用潜力。相较于传统深度卷积神经网络，图神经网络能够有效捕捉电网中蕴含的拓扑关系、电气相关性等显性图结构特征，并学习系统各节点潜在隐性关联，将拓扑结构特征与量测、状态、参数特征相融合，对电网拓扑处理具有较大优势。目前，图神经网络已在数据生成、源荷预测、潮流计算、状态估计、优化决策等关键任务上取得初步应用，整体处于探索和发展阶段。然而，图神经网络在应对拓扑变化的泛化性、可解释性、结合电力系统的强物理约束等方面仍存在诸多挑战。

针对上述挑战，未来需要围绕神经网络的泛化性、可解释性等方面展开进一步研究，在大规模电网拓扑图数据处理和融入物理方程约束等方面实现突破。在提升图神经网络的可解释性、满足物理约束的条件下，图神经网络能够在电网分析计算中发挥更加关键的作用。

参考文献

[1] LIAO Wenlong，YANG Dechang，WANG Yusen，et al. Fault diagnosis of power transformers using graph convolutional network[J]. CSEE Journal of Power and Energy Systems，2021，7(2)：241-249.

[2] MAO Weiyun，WEI Bengang，XU Xiangyi，et al. Power transformers fault diagnosis using graph neural networks based on dissolved gas data[J]. Journal of Physics：Conference Series，2022，2387(1)：012029.

[3] 龚逊东，费有蝶，凌佳凯，等. 基于深度神经网络伪量测建模的交直流混合配电网交替迭代法状态估计[J]. 电力建设，2022，43(10)：111-120.
GONG Xundong，FEI Youdie，LING Jiakai，et al. Alternating-iteration state estimation of AC/DC hybrid distribution system based on pseudo-measurement modeling using deep neural network[J]. Electric Power Construction，2022，43(10)：111-120(in Chinese).

[4] 蒋玮，汤海波，祁晖，等. 基于集成深度神经网络的配电网联络关系辨识技术[J]. 电力系统自动化，2020，44(1)：101-108.
JIANG Wei，TANG Haibo，QI Hui，et al. Distribution network connectivity recognition based on ensemble deep neural network[J]. Automation of Electric Power Systems，2020，44(1)：101-108(in Chinese).

[5] 武宇翔，韩肖清，牛哲文，等. 融合多注意力深度神经网络的可解释光伏功率区间预测[J]. 电网技术，2024，48(7)：2928-2939.
WU Yuxiang，HAN Xiaoqing，NIU Zhewen，et al. Interpretable photovoltaic power interval prediction using multi-attention deep neural networks[J]. Power System Technology，2024，48(7)：2928-2939(in Chinese).

[6] 李卓，王胤喆，叶林，等. 从感知-预测-优化综述图神经网络在电力系统中的应用[J]. 中国电力，2024，57(12)：2-16.
LI Zhuo，WANG Yinzhe，YE Lin，et al. The application of graph neural networks in power systems from perspective of perception-prediction-optimization[J]. Electric Power，2024，57(12)：2-16(in Chinese).

[7] DEFFERRARD M，BRESSON X，VANDERGHEYNST P. Convolutional neural networks on graphs with fast localized spectral filtering[C]//Proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona：Curran Associates Inc.，2016：3844-3852.

中国知网 https://www.cnki.net

[8] KIPF T N，WELLING M．Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv：1609.02907，2016.

[9] MICHELI A．Neural network for graphs：a contextual constructive approach[J]．IEEE Transactions on Neural Networks，2009，20(3)：498-511.

[10] CHIANG W L，LIU Xuanqing，SI Si，et al. Cluster-GCN：an efficient algorithm for training deep and large graph convolutional networks[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining．Anchorage：Association for Computing Machinery，2019：257-266.

[11] ATWOOD J，TOWSLEY D．Diffusion-convolutional neural networks[C]//Proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona：Curran Associates Inc.，2016：2001-2009.

[12] VELIČKOVIĆ P，CUCURULL G，CASANOVA A，et al. Graph attention networks[C]//Proceedings of the 6th International Conference on Learning Representations．Vancouver：ICLR，2018：2920-2931.

[13] CHANG Heng，RONG Yu，XU Tingyang，et al. Spectral graph attention network with fast eigen-approximation[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. New York：Association for Computing Machinery，2021：2905-2909.

[14] ZHANG Ruochi，ZOU Yuesong，MA Jian．Hyper-SAGNN：a self-attention based graph neural network for hypergraphs[C]//Proceedings of the the 8th International Conference on Learning Representations．Addis Ababa：ICLR，2020：2601-2618.

[15] LI Yujia，TARLOW D，BROCKSCHMIDT M，et al．Gated graph sequence neural networks[C]//Proceedings of the 4th International Conference on Learning Representations．San Juan：ICLR，2016：1-20.

[16] TAI Kaisheng，SOCHER R，MANNING C D．Improved semantic representations from tree-structured long short-term memory networks [C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing．Beijing：Association for Computational Linguistics，2015：1556-1566.

[17] FENG Jian，CHEN Shaojian．Link prediction based on orbit counting and graph auto-encoder[J]. IEEE Access，2020，8：226773-226783.

[18] DING Yulian，TIAN Liping，LEI Xiujuan，et al．Variational graph auto-encoders for miRNA-disease association prediction[J]. Methods，2021，192：25-34.

[19] VALSESIA D，FRACASTORO G，MAGLI E．Learning localized representations of point clouds with graph-convolutional generative adversarial networks[J]．IEEE Transactions on Multimedia，2021，23：402-414.

[20] LI Yujia，VINYALS O，DYER C，et al．Learning deep generative models of graphs[J]．arXiv preprint arXiv：1803.03324，2018.

[21] TANG Huidong，LI Chen，KAMEI S，et al．Molecular generative adversarial network with multi-property optimization[J]．arXiv preprint arXiv：2404.00081，2024.

[22] SEO Y，DEFFERRARD M，VANDERGHEYNST P，et al. Structured sequence modeling with graph convolutional recurrent networks [C]//Proceedings of the 25th International Conference on Neural Information Processing．Siem Reap：Springer，2018：362-373.

[23] ZHANG Yuxuan，LI Yuanxiang，WEI Xian，et al．Adaptive spatio-temporal graph convolutional neural network for remaining useful life estimation[C]//Proceedings of the 2020 International Joint Conference on Neural Networks．Glasgow：IEEE，2020：1-7.

[24] YU Bing，YIN Haoteng，ZHU Zhanxing．Spatio-temporal graph convolutional networks：a deep learning framework for traffic forecasting[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence. Stockholm：AAAI Press，2018：3634-3640.

[25] YAN Sijie，XIONG Yuanjun，LIN Dahua．Spatial temporal graph convolutional networks for skeleton-based action recognition [C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence and 30th Innovative Applications of Artificial Intelligence Conference and 8th AAAI Symposium on Educational Advances in Artificial Intelligence．New Orleans：AAAI Press，2018：912.

[26] JIN Guangyin，LIANG Yuxuan，FANG Yuchen，et al. Spatio-temporal graph neural networks for predictive learning in urban computing：a survey[J]．IEEE Transactions on Knowledge and Data Engineering，2024，36(10)：5388-5408.

[27] YANG Junhan，LIU Zheng，XIAO Shitao，et al．GraphFormers：GNN-nested transformers for representation learning on textual graph[C]//Proceedings of the 35th International Conference on Neural Information Processing Systems. Red Hook：Curran Associates Inc.，2021：28798-28810.

[28] DONG Yuxiao，CHAWLA N V，SWAMI A．metapath2vec：scalable representation learning for heterogeneous networks[C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining．Halifax：ACM，2017：135-144.

[29] WANG Xiao，JI Houye，SHI Chuan，et al．Heterogeneous graph attention network[C]//Proceedings of the World Wide Web Conference．San Francisco：ACM，2019：2022-2032.

[30] LIANG Ming，MENG Yao，WANG Jiyu，et al. FeederGAN：synthetic feeder generation via deep graph adversarial nets[J]．IEEE Transactions on Smart Grid，2021，12(2)：1163-1173.

[31] CHO Y H，LIU Shaohui，ZHU Hao，et al．Wind power scenario generation using graph convolutional generative adversarial network[C]//Proceedings of the 2023 IEEE Power & Energy Society General Meeting (PESGM)．Orlando：IEEE，2023：1-5.

[32] LIU Xin，YU Jingjia，GONG Lin，et al．A GCN-based adaptive generative adversarial network model for short-term wind speed scenario prediction[J]．Energy，2024，294：130931.

[33] 蔡高超，李国明，郭宇龙，等．基于多能互补及能源负荷预测的地区能源调度管理提升[C]//吉林省电机工程学会 2023 年学术年会获奖论文集．长春：吉林省电机工程学会，2023：256-567.

[34] YAO Tiechui，WANG Jue，WANG Yangang，et al．Very short-term forecasting of distributed PV power using GSTANN[J]. CSEE Journal of Power and Energy Systems，2024，10(4)：1491-1501，

[35] 欧阳永健，缪希仁，林蔚青，等．基于分层有向图与动态时空相关性的小区域光伏超短期预测方法[J]．电网技术，2024，48(6)：2458-2468.
OUYANG Yongjian，MIAO Xiren，LIN Weiqing，et al．Small area PV ultra-short-term prediction method using stratified digraph and dynamic spatial-temporal correlation[J]．Power System Technology，2024，48(6)：2458-2468(in Chinese).

[36] LIN Fan，ZHANG Yao，ZHAO Hanting，et al. Short-term probabilistic forecasting for regional PV power based on convolutional graph neural network and parameter transferring[J]．IEEE Transactions on Power Systems，2025，40(3)：2724-2736.

[37] 吕云龙，胡琴，熊俊杰，等．基于时空注意力卷积模型的超短期风电功率预测[J]．电网技术，2024，48(5)：2064-2073.
LÜ Yunlong，HU Qin，XIONG Junjie，et al．Ultra-short-term wind power prediction based on spatiotemporal attention convolution model[J]．Power System Technology，2024，48(5)：2064-2073(in Chinese).

[38] LIU Xiaoyan，ZHANG Yiran，ZHEN Zhao，et al．Spatio-temporal graph neural network and pattern prediction based ultra-short-term

中国知网 https://www.cnki.net

power forecasting of wind farm cluster[J]. IEEE Transactions on Industry Applications，2024，60(1)：1794-1803.

[39] YANG Mao，JU Chaoyi，HUANG Yutong，et al. Short-term power forecasting of wind farm cluster based on global information adaptive perceptual graph convolution network[J]. IEEE Transactions on Sustainable Energy，2024，15(3)：2063-2076.

[40] 董雷，陈振平，韩富佳，等. 基于图卷积神经网络与 K-means 聚类的居民用户集群短期负荷预测[J]. 电网技术，2023，47(10)：4291-4301.
DONG Lei，CHEN Zhenping，HAN Fujia，et al. Short-term load forecasting of residential user groups based on graph convolutional neural network and K-means clustering[J]. Power System Technology，2023，47(10)：4291-4301(in Chinese).

[41] 孟衡，张涛，王金，等. 基于多尺度时空图卷积网络与 Transformer 融合的多节点短期电力负荷预测方法[J]. 电网技术，2024，48(10)：4297-4305.
MENG Heng，ZHANG Tao，WANG Jin，et al. Multi-node short-term power load forecasting method based on multi-scale spatiotemporal graph convolution network and Transformer[J]. Power System Technology，2024，48(10)：4297-4305(in Chinese).

[42] LONG Zhuo，XU Zhiyuan，WU Gongping，et al. Parallel spatial-temporal graph attention network for short term multi-sequence load forecasting[J]. IEEE Transactions on Power Delivery，2025，40(3)：1244-1253.

[43] SHI Jinkai，ZHANG Weige，BAO Yan，et al. Load forecasting of electric vehicle charging stations：attention based spatiotemporal multi-graph convolutional networks[J]. IEEE Transactions on Smart Grid，2024，15(3)：3016-3027.

[44] 张延宇，张智铭，刘春阳，等. 基于动态自适应图神经网络的电动汽车充电负荷预测[J]. 电力系统自动化，2024，48(7)：86-93.
ZHANG Yanyu，ZHANG Zhiming，LIU Chunyang，et al. Electric vehicle charging load prediction based on dynamic adaptive graph neural network[J]. Automation of Electric Power Systems，2024，48(7)：86-93(in Chinese).

[45] 李常刚，李宝亮，曹永吉，等. 人工智能在电力系统潮流计算中的应用综述及展望[J]. 山东大学学报(工学版)，2025，55(5)：1-17.
LI Changgang，LI Baoliang，CAO Yongji，et al. Review and prospect on artificial intelligence application in power system power flow calculation[J]. Journal of Shandong University(Engineering Science)，2025，55(5)：1-17(in Chinese).

[46] PHAM T，LI Xingpeng. Neural network-based power flow model[C]//Proceedings of the 2022 IEEE Green Technologies Conference (GreenTech). Houston：IEEE，2022：105-109.

[47] 王渝红，沈靖，曾琦，等. 基于谱图论和图卷积神经网络的直流电网节点电压估计研究[J]. 电网技术，2022，46(2)：521-531.
WANG Yuhong，SHEN Jing，ZENG Qi，et al. Voltage estimation for dc grid nodes based on spectral theory and graph convolutional neural network[J]. Power System Technology，2022，46(2)：521-531.

[48] BEINERT D，HOLZHÜTER C，THOMAS J M，et al. Power flow forecasts at transmission grid nodes using Graph Neural Networks[J]. Energy and AI，2023，14：100262.

[49] 李骁皓，梁志坚，刘敏，等. 基于图多任务学习的潮流分析模型[J]. 南方电网技术，2023，17(11)：33-40.
LI Shenhao，LIANG Zhijian，LIU Min，et al. Power flow analysis model based on graph multi-task learning[J]. Southern Power System Technology，2023，17(11)：33-40(in Chinese).

[50] LIN Nan，ORFANOUDAKIS S，CARDENAS N O，et al. PowerFlowNet：power flow approximation using message passing graph neural networks[J]. International Journal of Electrical Power & Energy Systems，2024，160：110112.

[51] ZHAO Junbo，GÓMEZ-EXPÓSITO A，NETTO M，et al. Power system dynamic state estimation：motivations，definitions，methodologies，and future work[J]. IEEE Transactions on Power Systems，2019，34(4)：3188-3198.

[52] 黄蔓云，郭镜玮，臧海祥，等. 基于消息传递图神经网络的电力系统状态估计[J]. 电网技术，2023，47(11)：4396-4404.
HUANG Manyun，GUO Jingwei，ZANG Haixiang，et al. State estimation of power system based on a message passing neural network[J]. Power System Technology，2023，47(11)：4396-4404(in Chinese).

[53] 陈源奕，王玉彬，杨强. 基于时空特征图卷积网络的配电网实时状态估计方法[J]. 高电压技术，2021，47(7)：2386-2395.
CHEN Yuanyi，WANG Yubin，YANG Qiang. Real-time state estimation method for distribution networks based on spatial-temporal feature graph convolution network[J]. High Voltage Engineering，2021，47(7)：2386-2395(in Chinese).

[54] KUNDACINA O，COSOVIC M，VUKOBRATOVIC D. State estimation in electric power systems leveraging graph neural networks[J]. arXiv preprint arXiv：2201.04056，2022.

[55] 胡家祥，曹迪，胡维昊，等. 融入拓扑知识的图神经网络配电网抗差状态估计方法[J]. 电力系统自动化，2023，47(10)：84-97.
HU Jiaxiang，CAO Di，HU Weihao，et al. Robust state estimation method for distribution network based on graph neural network incorporating topology knowledge[J]. Automation of Electric Power Systems，2023，47(10)：84-97(in Chinese).

[56] REN Zhengxing，CHU Xiaodong，YE Hua. State estimation for reconfigurable distribution systems using graph attention network[J]. IEEE Access，2023，11：107237-107250.

[57] 王铮澄，周艳真，郭庆来，等. 考虑电力系统拓扑变化的消息传递图神经网络暂态稳定评估[J]. 中国电机工程学报，2021，41(7)：2341-2349.
WANG Zhengcheng，ZHOU Yanzhen，GUO Qinglai，et al. Transient stability assessment of power system considering topological change：a message passing neural network-based approach[J]. Proceedings of the CSEE，2021，41(7)：2341-2349(in Chinese).

[58] CHEN Qifan，BU Siqi，WANG Huaiyuan，et al. Real-time multi-stability risk assessment and visualization of power systems：a graph neural network-based method[J]. IEEE Transactions on Power Systems，2025，40(4)：2955-2968.

[59] 庄颖睿，肖谭南，程林，等. 基于时空图卷积网络的电力系统暂态稳定评估[J]. 电力系统自动化，2022，46(11)：11-18.
ZHUANG Yingrui，XIAO Tannan，CHENG Lin，et al. Transient stability assessment of power system based on spatio-temporal graph convolutional network[J]. Automation of Electric Power Systems，2022，46(11)：11-18(in Chinese).

[60] 卢锦玲，周阳，颜禄涵，等. 基于残差时空图神经网络的电力系统暂态稳定评估[J]. 电力科学与工程，2022，38(9)：54-64.
LU Jinling，ZHOU Yang，YAN Luhan，et al. Transient stability assessment of power system based on residual spatiotemporal graph neural network[J]. Electric Power Science and Engineering，2022，38(9)：54-64(in Chinese).

[61] 刘浩宇，刘挺坚，刘友波，等. 基于图卷积神经网络的直流送端系统暂态过电压评估[J]. 电力系统保护与控制，2023，51(23)：71-81.
LIU Haoyu，LIU Tingjian，LIU Youbo，et al. A method for evaluating transient overvoltage of an HVDC sending-end system based on a graph convolutional network[J]. Power System Protection and Control，2023，51(23)：71-81(in Chinese).

[62] WANG Tianjing，TANG Yong. Transient stability preventive control based on graph convolution neural network and transfer deep reinforcement learning[J]. CSEE Journal of Power and Energy

中国知网 https://www.cnki.net

Systems，2025，11(1)：136-149.
[63] YU Yin，JIANG Xinyuan，HUANG Daning，et al. PIDGeuN：graph neural network-enabled transient dynamics prediction of networked microgrids through full-field measurement[J]. IEEE Access，2024，12：49464-49475.
[64] XU Peidong，DUAN Jiajun，ZHANG Jun，et al. Active power correction strategies based on deep reinforcement learning—part I：a simulation-driven solution for robustness[J]. CSEE Journal of Power and Energy Systems，2022，8(4)：1122-1133.
[65] LI Jinhao，ZHANG Ruichang，WANG Hao，et al. Deep reinforcement learning for voltage control and renewable accommodation using spatial-temporal graph information[J]. IEEE Transactions on Sustainable Energy，2024，15(1)：249-262.
[66] WANG Yi，QIU Dawei，WANG Yu，et al. Graph learning-based voltage regulation in distribution networks with multi-microgrids[J]. IEEE Transactions on Power Systems，2024，39(1)：1881-1895.
[67] QIN Jingtao，YANG Rui，YU Nanpeng. Physics-informed graph neural networks for collaborative dynamic reconfiguration and voltage regulation in unbalanced distribution systems[J]. IEEE Transactions on Industry Applications，2025，61(2)：2538-2548.
[68] CHEN Li’ao，ZHOU Siyi，LIANG Xingyu，et al. Predicting power dispatch for unit commitment problems using graph-temporal convolutional networks with constrained learning[J]. IEEE Transactions on Industrial Informatics，2025，21(7)：5734-5745.
[69] RAMESH A V，LI Xingpeng. Spatio-temporal deep learning-assisted reduced security-constrained unit commitment[J]. IEEE Transactions on Power Systems，2024，39(2)：4735-4746.
[70] LUO Yuankai，SHI Lei，WU Xiaoming. Classic GNNs are strong baselines：reassessing GNNs for node classification[J]. Advances in Neural Information Processing Systems，2024，37：97650-97669.
[71] AKKAS S，AZAD A. GNNShap：scalable and accurate GNN explanation using shapley values[C]//Proceedings of the ACM Web Conference 2024. Singapore：ACM，2024：827-838.
[72] GU Sili，QIAO Ji，SHI Wenlong，et al. Multi-task transient stability assessment of power system based on graph neural network with interpretable attribution analysis[J]. Energy Reports，2023，9(S10)：930-942.
[73] HUANG Qiang，YAMADA M，TIAN Yuan，et al. GraphLIME：local interpretable model explanations for graph neural networks[J]. IEEE Transactions on Knowledge and Data Engineering，2023，35(7)：6968-6972.
[74] YING R，BOURGEOIS D，YOU Jiaxuan，et al. GNNExplainer：generating explanations for graph neural networks[C]//Proceedings of the 33rd International Conference on Neural Information Processing Systems. Vancouver：Curran Associates Inc.，2019：829.
[75] HUANG Bin，WANG Jianhui. Applications of physics-informed neural networks in power systems-a review[J]. IEEE Transactions on Power Systems，2023，38(1)：572-588.


高昆仑

在线出版日期：2026-01-27。
收稿日期：2025-08-06。
作者简介：
高昆仑(1972)，男，博士，教授级高级工程师，研究方向为电力系统自动化与信息化技术、电网图计算技术，E-mail：gkl@epri.sgcc.com.cn；
姚铁锤(1993)，男，博士，工程师，通信作者，研究方向为电网时空数据分析、电力人工智能应用技术，E-mail：yaotiechui@epri.sgcc.com.cn。

（责任编辑 徐梅 宋钰龙）

中国知网 https://www.cnki.net